

Оркестратор ИИ-моделей


Техническая спецификация для реализации · CLI-обёртка над двумя агентными каркасами с автоматическим выбором модели под задачу

1. Цель

Единая CLI-команда, которая принимает задачу на естественном языке, самостоятельно определяет её сложность и направляет в подходящий агентный каркас с подходящей моделью.

Главная экономическая задача — беречь лимит подписки Claude Pro. Рутинные задачи уходят на бесплатные и дешёвые модели через OpenRouter, а Claude Code вызывается только там, где дешёвые модели объективно не справляются. Это кратно растягивает окно подписки.

2. Общая схема



3. Принцип маршрутизации

По умолчанию всё идёт вниз. Подъём вверх происходит только по двум причинам: явная команда пользователя либо провал на нижнем уровне.

3.1. Что уходит вниз (OpenRouter)

- Механический рефакторинг: переименования, вынос констант, разбиение файлов, приведение к единому стилю
- Написание тестов по существующему образцу
- Докстринги, комментарии, типизация
- Правки в пределах одного файла
- Задачи, где есть понятный образец в кодовой базе

3.2. Что уходит вверх (Claude Code)

- Смысловой рефакторинг: смена архитектуры, развязка зависимостей, переписывание модуля под другой контракт
- Баги с неочевидной причиной
- Задачи, затрагивающие много связанных файлов
- Всё, что провалилось на нижнем уровне

3.3. Разделительный критерий

Ключевой вопрос для рефакторинга: меняется ли поведение кода. Переименование и перенос — нет, значит вниз. Меняется контракт или структура — вверх. Без этого разделения механические правки, которых всегда больше, сожгут лимит подписки.

4. Лестница моделей

Ур.	Модель	Цена (вход/выход за 1М)	Назначение
L0	cohere/north-mini-code:free	\$0 / \$0	Тривиальное: докстринги, форматирование
L1	poolside/laguna-m.1:free	\$0 / \$0	Простые правки в одном файле
L2	MiniMax M3	\$0.60 / \$2.40	Основная рабочая лошадка
L3	Kimi K2.7 Code	≈ \$0.95 / \$4.00	Долгие агентные сессии
L4	Claude Code (Pro)	подписка	Архитектура, сложные баги

Обоснование выбора

- North Mini Code — Cohere обучала её работать внутри агентных каркасов OpenCode и SWE-Agent, а не просто писать код. Контекст 256K, вывод до 64K. Рейтинг Programming #16 на OpenRouter.
- Laguna M.1 — флагманский кодовый агент Poolside, tool calling + reasoning, контекст 256K. Programming #17.
- MiniMax M3 — самая дешёвая модель, перешагнувшая 80% на SWE-bench Verified (80.5%). Лучшее соотношение цена/качество на рынке.
- Kimi K2.7 Code — режет ≈30% думающих токенов относительно K2.6, что прямо снижает стоимость долгих прогонов. Линейка выигрывает на агентной стабильности: восстанавливаемые сбои, ровный tool calling через длинные сессии.

Предупреждение по лицензиям и данным

Poolside прямо заявляет: при бесплатном использовании Laguna они могут использовать входы и выходы для обучения своих моделей. На приватном репозитории это следует учитывать. North Mini Code — Apache 2.0, ограничений нет.

Лимиты бесплатного тира OpenRouter

20 запросов в минуту, 200 в сутки. При балансе от \$10 на аккаунте порог поднимается до 1000 в сутки. Состав бесплатных моделей ротится без предупреждения — конфиг должен допускать список фолбэков, а не жёсткий единственный ID.

5. Алгоритм классификации

Три уровня, по возрастанию стоимости решения. Останавливаемся на первом сработавшем.

Уровень 1 — явное указание

Префикс в команде переопределяет всё: /l4 почини авторизацию отправляет напрямую в Claude Code. Роутер не думает.

Уровень 2 — эвристики

Мгновенно и бесплатно, ловят около 70% случаев:

- Число файлов, которые задача предположительно затронет

- Ключевые слова: «архитектура», «миграция», «развяжи», «перепиши» → вверх; «переименуй», «добавь тест», «докстринг», «отформатируй» → вниз
- Правка по образцу против необходимости понять чужой код
- Флаг: эта задача уже проваливалась на нижнем уровне

Уровень 3 — LLM-классификатор

Всё, что не поймали эвристики, отправляется в самую дешёвую модель с промптом «оцени сложность от 1 до 5, ответь одной цифрой». Стоит доли цента, задержка порядка секунды.

6. Эскалация

Роутер будет ошибаться — это неизбежно. Механизм подъёма обязателен, иначе дешёвые модели начнут портить код.

6.1. Триггеры подъёма

- Каркас вернул ненулевой код выхода
- Превышен лимит шагов на задачу
- Тесты не прошли после завершения работы агента
- Агент заиклился: повторяющиеся одинаковые вызовы инструментов
- Явная команда пользователя после просмотра результата

6.2. Перенос контекста между каркасами

Главная сложность схемы с двумя каркасами: при переходе OpenCode → Claude Code накопленный контекст теряется. Решение частичное, но рабочее:

- Обёртка ведёт собственный журнал задачи: исходная формулировка, список изменённых файлов, вывод команд, попытки и их результаты
- Перед эскалацией собирается стартовый промпт: журнал + `git diff` текущего состояния
- Файлы уже на диске — большая часть состояния восстановима из репозитория, а не из памяти модели

Что перенести не удастся: ход рассуждения нижней модели — какие гипотезы она отвергла и почему. И кэш промптов, который при смене каркаса сбрасывается в ноль. Поскольку при правильной маршрутизации эскалации редки, эти потери приемлемы.

6.3. Учёт лимита подписки

Перед подъёмом на L4 роутер проверяет остаток окна Pro. Если окно на исходе — лучше поставить задачу в очередь или предложить пользователю подождать, чем сжечь остаток на задаче, которую дожевал бы MiniMax. Нужна и обратная эскалация: при исчерпании лимита задача уходит вниз с пометкой в журнале.

7. Предохранители

- Обязательный коммит перед запуском любого агента. Откат одной командой, без этого запускать дешёвые модели на живом репозитории нельзя.
- Жёсткий лимит шагов на задачу. Защита от заикливания и от выжигания квоты.
- Потолок стоимости на задачу. Прерывание при превышении.
- Журнал решений роутера. Записывать: задачу, выбранный уровень, основание выбора, исход, число шагов, стоимость.

Журнал — не отладочный инструмент, а источник данных. Через неделю работы он покажет, какие задачи куда просились в реальности, и позволит подкрутить пороги под конкретный стиль работы вместо догадок.

8. Состав кода

Модуль	Ответственность
cli.py	Разбор команды, префиксы уровней, вывод результата

Модуль	Ответственность
router.py	Три уровня классификации, выбор каркаса и модели
runner.py	Спавн процессов OpenCode и Claude Code, чтение потоков
escalate.py	Детекция провала, сборка контекста, повторный запуск
budget.py	Учёт стоимости, отслеживание окна подписки Pro
journal.py	Запись решений и исходов

Агентный цикл писать не нужно. Чтение файлов, правки, bash, откат при ошибке, сжатие контекста — всё это уже реализовано в OpenCode и Claude Code. Собственный код — только маршрутизация поверх готовых каркасов.

9. Порядок реализации

Строго по этапам. Не собирать всю лестницу сразу.

Этап 1 — база

- Поднять OpenCode, подключить OpenRouter как провайдера
- Проверить работоспособность L0 и L1 на реальных задачах в репозитории
- Убедиться, что tool calling у бесплатных моделей держится в длинной сессии — это главный технический риск всей схемы

Этап 2 — обёртка

- CLI, умеющая спавнить оба каркаса
- Переключение уровня вручную, через префикс команды
- Журнал решений включён с первого дня

Этап 3 — наблюдение

Неделя работы с ручным переключением. Цель — собрать данные: какие задачи реально требовали L4, как часто дешёвые модели не справлялись, где проходит граница.

Этап 4 — автоматизация

- Эвристики, откалиброванные по журналу за неделю
- LLM-классификатор для остатка
- Автоматическая эскалация с переносом контекста

Строить автоматическую эскалацию до того, как известна её реальная частота — оптимизация вслепую. Пороги должны опираться на собранные данные, а не на предположения.

10. Открытые вопросы для реализации

- Язык обёртки и основного проекта — определить перед началом
- Способ оценки числа затрагиваемых файлов до запуска агента: по ключевым словам, по грег, или спрашивать у дешёвой модели
- Формат журнала: JSONL против SQLite — зависит от того, планируется ли аналитика поверх
- Механизм определения остатка окна Pro — надёжного программного способа может не оказаться, возможно потребуется эвристика по времени и объёму запросов

11. Проверить перед стартом

Данные в документе актуальны на июль 2026 года и могут устареть:

- Состав бесплатных моделей на openrouter.ai/models с фильтром Price: Free — список ротируется постоянно
- Актуальные цены L2 и L3 — приведённые значения взяты из взвешенных средних OpenRouter и обзоров
- Текущие лимиты подписки Claude Pro
- Режимы маршрутизации провайдеров на OpenRouter: режим Exacto оптимизирует точность tool calling — для агентной работы предпочтителен